

sed und Reguläre Ausdrücke

Mit dem Arbeitsblatt über den Stream-Editor **sed** haben Sie gelernt, dass wir auf einfache Weise Zeilen löschen oder einen Text durch einen anderen ersetzen können.

Beim Suchen und Ersetzen haben wir als Suchbegriff fixe Texte verwendet. **sed** kann aber Reguläre Ausdrücke als Suchbegriff verwenden. Und der Text, der eingefügt wird, kann Teile des gefundenen Textes verwenden.

Hinweis

Zu allen Beispielen finden Sie die benötigten, kleinen Textdateien unter diesem Dokument auf der Modul-Webseite.

Suche mit Regulärem Ausdruck

Als erstes versuchen wir, nicht mehr einen fixen Text zu finden, sondern ein Textmuster.

Der Reguläre Ausdruck zur Erkennung einer E-Mail-Adresse mit dem Online-Tool lautet (versuchen Sie, den Ausdruck nachzuvollziehen):

```
\b.+@.+\. .+\b
```

Jetzt werden wir diesen Ausdruck suchen und durch den fixen Text "gültige Mail-Adresse" ersetzen. Leider gibt es verschiedene Dialekte von Regulären Ausdrücken. Sie sind sich in der Regel sehr ähnlich, aber genau gleich sind sie leider nicht.

Wenn wir mit `bash` arbeiten, müssen wir gegenüber dem Online-Tool vor mehrere Symbole einen Backslash schreiben (`\`). Im Befehl, den wir gerade ausführen möchten, ist das beim Pluszeichen (`+`). (Auf dem Hilfsmittel zum Modul 122 finden Sie die jeweils korrekte Schreibweise.)

Der Befehl lautet dann also:

```
sed -e 's/\b.+@.+\. .+\b/gültige Mail-Adresse/g' mail.txt
```

Da wir die Ausgabe nicht umleiten, erscheint sie einfach auf der Konsole.

Die Ausgabe sieht jetzt so aus:

```
gültige Mail-Adresse
hans@muster
gültige Mail-Adresse
gültige Mail-Adresse
gültige Mail-Adresse
```

Damit können wir viel flexiblere Suchanfragen formulieren. Wir können nach Strukturen suchen statt nach festen Begriffen.

Ersetzen mit Teilen des gefundenen Textes

Jetzt geht es darum, einen gefundenen Text nicht einfach zu ersetzen, sondern Teile davon in den neuen Text zu übernehmen.

Wir beginnen wieder mit einem bekannten Beispiel. Auf dem Arbeitsblatt zum Stream Editor `sed` haben Sie eine Aufgabe gelöst, in der Sie den Ortsnamen "MuttENZ" in einer Datei durch den Text "BBZBL" ersetzt haben. Der Befehl lautete:

```
sed -e 's/MuttENZ/BBZBL/g' ch-orte.txt > ch-orte-neu.txt
```

Nun möchten wir den Text nicht einfach ersetzen, sondern nur ergänzen. Wir möchten dem Ortsnamen "MuttENZ" den Text " (BBZBL)" hinzufügen.

Damit wir den gefundenen Text beim Ersetzen verwenden können, müssen wir den Suchtext gruppieren. Das geschieht mit runden Klammern (vor die wir jeweils einen Backslash (\) setzen müssen). Dann können wir im "Ersetzen"-Teil diese Gruppe referenzieren. Das macht man mit einem Backslash und der Nummer der Gruppe, die verwendet werden soll. In unserem Fall haben wir nur eine Gruppe, also ist es die erste.

```
sed -e 's/(MuttENZ)/\1 (BBZBL)/g' ch-orte.txt
```

Die entsprechende Zeile sieht dann so aus:

```
MuttENZ (BBZBL)
```

Machen wir ein komplexeres Beispiel. Eine Telefonnummer in der Schweiz besteht aus 10 Stellen. Drei Stellen sind die Vorwahl, danach folgt eine siebenstellige Nummer. Diese kann man auf verschiedene Arten schreiben. Wir möchten nun alle Telefonnummern so formatieren, dass sie dem folgenden Muster entsprechen: 061 552 00 00. Sie soll also in vier Gruppen aufgeteilt werden, egal ob sie so abgespeichert wurde oder nicht.

Der Inhalt der Datei `telnr.txt` sieht so aus:

```
061 123 45 67
061 1112233
611234567
0611234567
061    123    45    78
1234567890
```

Wenn wir uns einen Regulären Ausdruck zusammensetzen möchten, dann müssen wir den Aufbau einer Telefonnummer kurz analysieren.

- zuerst kommen 3 Ziffern, wobei die erste Ziffer eine 0 sein muss
- dann können Leerzeichen folgen, müssen aber nicht
- jetzt folgen 3 Ziffern
- dann können Leerzeichen folgen, müssen aber nicht
- jetzt folgen 2 Ziffern
- dann können Leerzeichen folgen, müssen aber nicht
- jetzt folgen nochmals 2 Ziffern

Schreiben wir das in einen Regulären Ausdruck, dann sieht der so aus:

```
0[1-9]\{2,2\}\s*[0-9]\{3,3\}\s*[0-9]\{2,2\}\s*[0-9]\{2,2\}
```

Damit wir die einzelnen Teile der Telefonnummer im “Ersetzen”-Teil verwenden können, unterteilen wir diesen Ausdruck mit Hilfe der runden Klammern in einzelne Gruppen (hier farblich hervorgehoben):

```
\(0[1-9]\{2,2\}\)\s*\([0-9]\{3,3\}\)\s*\([0-9]\{2,2\}\)\s*\([0-9]\{2,2\}\)
```

Jetzt können wir den ganzen Befehl zusammensetzen (auch hier wieder die Farben als Hilfe):

```
sed -e 's/\(0[1-9]\{2,2\}\)\s*\([0-9]\{3,3\}\)\s*\([0-9]\{2,2\}\)\s*\([0-9]\{2,2\}\)/\1 \2 \3 \4/g' telnr.txt
```

Als Resultat erhalten wir die folgende Ausgabe:

```
061 123 45 67
061 111 22 33
611234567
061 123 45 67
061 123 45 78
1234567890
```

Alle Einträge, die als korrekte Telefonnummern erkannt wurden, hat **sed** so formatiert, wie wir das haben wollten.